자동 생성 온톨로지를 이용한 LLM 데이터베이스 질의 성능 비교

고은비[1], 김연주[2], 최혜림[2], 정종진[2*]
[1]대진대학교 일반대학원 방산AI융합학과, [2]대진대학교 AI빅데이터공학과

Performance Comparison of LLM Database Querying Using Automatically Generated Ontologies

Eunbi Ko[1], Yeonju Kim[2], Hyerim Choi[2], Jongjin Jeong[2*]
[1]Dept. of Defense AI Convergence, Graduate School, Daejin University
[2]Dept. of AI·BigData Engineering, Daejin University

Abstract - LLM이 데이터베이스에 질의할 때 온톨로지로 개념과 관계를 명시하면 정확도가 향상된다는 보고가 있으나, 모든 DB에 온톨로지를 수작업으로 구축하는 데에는 부담이 크다. 본 연구는 DB로부터 자동 생성한 온톨로지가 실제 질의에 도움이 되는지, 그리고 온톨로지를 어떻게 연결하는 것이 정확도에 유리한지를 BIRD의 두 데이터베이스에서 비교하였다. 온톨로지를 사용하지 않는 조건, 온톨로지를 검색하여 스키마를 파악한 뒤 SQL을 사용하는 조건, SPARQL로 질의하면 매핑을 통해 이를 SQL로 변환하여 실행하는 조건을 비교하였다. 그 결과, 자동 생성한 온톨로지를 스키마 탐색에 활용한 경우 DB만 사용한 경우보다 정확도가 미세하게 높았으나, 신뢰구간이 겹쳐 차이를 단정하기는 어려웠다. 온톨로지의 연결 방식으로는 스키마 탐색에 활용하는 방식이 SPARQL을 SQL로 변환하는 방식보다 정확도가 높은 경향을 보였다.

1. 서 론

LLM으로 자연어 질문을 질의로 변환하여 DB에 접근하는 방식은 SQL로 직접 질의하는 방식(text-to-SQL)과 온톨로지 기반 지식 그래프에 SPARQL(SPARQL Protocol and RDF Query Language)로 질의하는 방식이 연구되어 왔다. 전자의 벤치마크 중 하나인 BIRD(BIg Bench for LaRge-scale Database Grounded Text-to-SQL Evaluation)는 37개 분야의 실제 DB 95개로 이루어져 있으며, 발표 당시 ChatGPT의 실행 정확도는 40.08%로 사람의 92.96%에 크게 미치지 못하였다[1]. 후자와 관련하여 한 연구에서는 같은 DB에 대해 GPT-4가 SQL로 직접 질의한 경우 정확도가 16%였으나, 온톨로지와 매핑으로 구성한 지식 그래프를 통해 질의한 경우 54%로 향상되었다고 보고하였다[2]. 다만 이 결과는 표준 보험 스키마에 직접 생성한 소규모 데이터로 테이블당 수 개 행과 질문 43개에서 벤치마크와 함께 제공된 온톨로지를 사용하여 얻은 것으로, 다른 DB에서도 동일한 경향이 나타나는지, 또 온톨로지를 DB마다 직접 수작업으로 구축하지 않고도 유사한 효과를 얻을 수 있는지는 본 연구가 조사한 범위에서는 확인되지 않았다.

온톨로지를 DB마다 구축하는 데에는 수작업이 많이 소요된다고 지적되고 있다[2]. 이를 줄이기 위하여 DB로부터 온톨로지를 자동 생성하는 방법과 이를 평가하는 벤치마크(RODI[3], BURR[4])가 제안되었다. 이들 가운데 상당수는 이미 존재하는 목표 온톨로지에 DB를 대응시키거나 스키마의 구조를 규칙에 따라 변환하는 방식이어서 컬럼의 의미와 맥락을 반영하는데 한계가 있을 수 있으며[5], 본 연구가 조사한 범위에서는 LLM을 이용하여 DB만으로 온톨로지를 처음부터 생성하는 방법은 많지 않았다[4]. 이러한 방법 중 하나인 RIGOR(Retrieval-augmented Iterative Generation of RDB Ontologies)는 직접 매핑으로 스키마를 포괄한 뒤 LLM과 검색 증강 생성으로 의미를 보강하고 검증한다[5]. 그러나 이와 같이 자동 생성한 온톨로지가 실제 질의에서 도움이 되는지는 확인되지 않았다.

온톨로지가 DB만 사용할 때보다 LLM의 질의 정확도를 높인다는 보고는 있으나[2], 이는 제공된 온톨로지 하나로 얻은 결과이다. 이에 본 연구의 기여는 다음과 같다. 첫째, 수작업이 아닌 DB로부터 자동 생성한 온톨로지를 LLM 에이전트의 질의에 활용하였을 때의 정확도를 DB만 사용한 경우와 비교하였다. 둘째, 온톨로지를 LLM에 연결하는 두 방식, 즉 스키마 탐색에 활용하는 방식과 SPARQL 직접 질의에 활용하는 방식의 정확도를 동일한 조건에서 비교하였다. 이를 위하여 BIRD에서 두 DB를 선정하고, DB만 입력받아 LLM으로 온톨로지를 생성하는 방법인 RIGOR[5]로 각 DB의 온톨로지를 생성하였다. 이후 동일한 에이전트가 DB에 접근하는 방식만 달리한 세 조건을 설정하였다. 첫째는 SQL만 사용하는 조건, 둘째는 온톨로지를 SPARQL로 검색한 뒤 SQL을 사용하는 조건, 셋째는 Ontop[6]으로 SPARQL을 SQL로 변환하여 사용하는 조건이다.

2. 본 론

2.1 데이터세트 구성

2.1.1 데이터베이스 선정 기준

본 연구는 BIRD train의 69개 데이터베이스 중 다음 조건을 만족하는 데이터베이스를 후보로 한정하였다. 먼저 파일 크기가 1GB 이하이면서 테이블이 10개 이상 20개 이하인 데이터베이스만 고려하였다. 마지막으로 RIGOR의 스키마 형식은 컬럼 하나로 이루어진 외래 키(Foreign Key)만 표현하므로, 복합 외래 키가 있는 데이터베이스는 대상에서 제외하였다. 그 결과 후보 8개를 얻었다. 후보들의 데이터 스키마를 그래프로 표현하고, 이때 그래프 이론[7]의 정의에 따라, 같은 두 정점 사이의 간선이 하나뿐이고 자기 자신으로 이어지는 간선이 없는 단순 그래프를 사용하였다. 정점 수 V는 테이블 수, 간선 수 E는 외래 키로 이어진 서로 다른 테이블 쌍의 수, 연결 요소 수 C는 외래키로 서로 닿지 않는 테이블 묶음의 수로 정의하였으며, 순환 계수 μ는 그래프에 포함된 독립적인 순환의 수로 정의하였다[7][8].

V는 테이블 수, E는 외래 키로 이어진 서로 다른 테이블 쌍의 수를 세었다. 이때 같은 두 테이블 사이의 중복 외래 키는 하나로 세고 자기 자신을 참조하는 외래 키는 세지 않았으며, 온톨로지 생성에 사용하는 RIGOR의 스키마 형식이 컬럼 하나로 이루어진 외래 키만 표현할 수 있으므로 여러 컬럼으로 이루어진 복합 외래 키도 간선으로 세지 않았다. C는 이렇게 만든 그래프에서 외래 키를 따라 서로 닿는 테이블을 한 묶음으로 보아 묶음의 수를 세었다. 후보 중 간선 수가 가장 많은 movie_3와 순환 계수가 가장 큰 synthea를 선정하였으며, 두 데이터베이스의 구조는 표 1과 같다.

<표 1> 선택된 데이터베이스의 구조

DB	V	E	C	μ
movie_3	16	20	2	6
synthea	11	18	1	8

2.1.2 데이터 전처리

Ontop은 SQLite를 지원하지 않지만 BIRD의 train 데이터는 SQLite 파일로 제공되므로, 데이터와 제약 조건을 그대로 보존해 PostgreSQL로 옮기고 모든 테이블의 행 값이 원본과 일치함을 확인했다. 질문은 BIRD 9,428개 중 선택한 두 데이터베이스의 질문 전체(movie_3 325개, synthea 185개, 합계 510개)를 선별 없이 사용했다.

BIRD의 정답 SQL은 SQLite 문법이어서 PostgreSQL에서 그대로 실행되지 않는 경우가 있어, 오류가 나는 SQL은 sqlglot과 SQLite의 암묵적 동작(대소문자를 구분하지 않는 비교, 문자열과 숫자의 자동 변환, 날짜 함수 등)을 PostgreSQL 식으로 옮기는 규칙으로 변환했다. 변환한 SQL의 결과가 원본 SQLite 결과와 같은 경우만 정답으로 채택했으며, 그 결과 movie_3는 320개, synthea는 159개로 모두 479개가 되었다. 나머지 31개는 정렬 없는 LIMIT 등으로 결과가 SQLite와 달라 정답이 하나로 정해지지 않거나, SQLite에만 있는 문법이나 데이터베이스에 없는 테이블을 쓰는 정답이어서 변환하지 못해 채점에서 제외했다.

2.1.3 질문 난이도 분류

질문의 난이도는 Spider[9]의 SQL hardness 기준을 정답 SQL에 적용해 easy, medium, hard, extra의 네 등급으로 나누었다. 정답 SQL에서 SQL 요소 수(WHERE, GROUP BY, ORDER BY, LIMIT, 조인, OR, LIKE), 중첩 수(조건 안의 서브쿼리와 집합 연산), 그 밖의 요소 수(집계 함수, SELECT 항목, WHERE 조건, GROUP BY 컬럼이 둘 이상인지)를 센다. easy는 SQL 요소가 하나 이하이고 중첩과 그 밖의 요소가 없는 경우이고, medium은 중첩 없이 두 요소 모두 적은 경우이다. hard는 요소가 더 많거나 서브쿼리가 하나 있는 경우, extra는 이보다 복잡한 나머지이다. Spider는 자체 SQL 파서를 사용하나 본 연구는 sqlglot으로 같은 요소를 세었다. 정답으로 채택한 479개 질문의 난이도 분포는 표 2와 같다.

<표 2> 질문 난이도 분류

DB(%)	easy	medium	hard	extra
movie_3	14.4	41.3	25.3	19.1
synthea	0.6	64.8	11.3	23.3

2.2 온톨로지 구성 및 데이터베이스 연결

2.2.1 RIGOR 기반 온톨로지 생성[5]

각 데이터베이스의 스키마는 RIGOR로 OWL 2 DL 온톨로지로 변환했다.

RIGOR는 먼저 테이블을 클래스로, 컬럼을 데이터 속성으로, 외래 키를 객체 속성으로 옮기는 Direct Mapping으로 기본 온톨로지를 만든다. 이어서 생성용 LLM이 이 기본 온톨로지를 스키마의 의미에 맞게 보강하고, 판정용 LLM이 보강 결과를 검토한다. 두 역할에는 모두 claude-opus-5-5를 사용했다. 생성된 온톨로지는 movie_3가 클래스 16개, 데이터 속성 67개, 객체 속성 24개이고, synthea가 클래스 11개, 데이터 속성 67개, 객체 속성 18개이다. 클래스 수는 두 데이터베이스 모두 테이블 수와 같다. 생성 결과가 데이터베이스를 빠짐없이 반영하는지 확인하기 위해, 모든 테이블이 클래스로, 모든 컬럼이 속성으로 들어갔는지와 속성의 도메인과 범위 자료형이 컬럼 타입과 어긋나지 않는지를 점검했다.

2.2.2 R2RML 매핑 및 Ontop 연결[6]

Ontop(5.5.0)은 관계형 데이터베이스를 복사하지 않고 가상 지식 그래프로 노출하는 도구이다[6]. 온톨로지와 R2RML(RDB to RDF Mapping Language) 매핑을 받아, 에이전트가 쓴 SPARQL 질의를 매핑에 따라 SQL로 번역해 PostgreSQL에서 실행하고 그 결과를 돌려준다. 그런데 RIGOR는 OWL 온톨로지만 만들 뿐 R2RML 매핑은 내보내지 않으므로, RIGOR의 온톨로지와 스키마 JSON에서 W3C R2RML 매핑을 만드는 변환기를 구현해 사용했다. 매핑 규칙은 다음과 같다. 테이블마다 TriplesMap(표를 RDF의 문장인 대상, 속성, 값으로 바꾸는 규칙 묶음)를 하나 두고, 기본 키(Primary Key)로 행의 IRI(Internationalized Resource Identifier)를 만들어 그 테이블의 클래스를 부여한다. 외래 키가 아닌 컬럼은 해당 데이터 속성으로, 외래 키 컬럼은 참조하는 테이블의 행 IRI를 가리키는 객체 속성으로 옮긴다. 속성과 클래스의 이름은 RIGOR가 온톨로지를 만들 때 쓴 이름 규칙과 같은 함수로 만들어, 온톨로지에 실제로 있는 IRI와 일치시켰다. 기본 키가 없는 테이블은 행 내용의 해시와 행 번호로 행 IRI를 만들었고, 온톨로지에 두 클래스를 잇는 속성이 있는 연결 테이블은 그 속성으로도 매핑했다. 날짜 형식의 값이 문자열로 저장된 컬럼은 날짜 자료형으로 읽히도록 별도의 TriplesMap으로 변환했다. 생성된 매핑은 movie_3가 TriplesMap 37개(테이블 16개, 날짜 변환 19개, 연결 속성 2개), synthea가 11개이다. 매핑이 온톨로지와 데이터베이스를 정확히 반영하는지는 Ontop으로 직접 질의해 확인했다. 클래스별 인스턴스 수가 테이블의 행 수와 같은지, 속성별 트리플 수가 데이터베이스에서 센 값 수(NULL이 아닌 값, 연결 테이블은 서로 다른 외래 키 쌍)와 같은지를 비교했고, OWL의 클래스와 속성이 모두 매핑에 들어 있는지도 점검했다.

2.3 실험 및 평가

2.3.1 실험 환경 및 평가 방법

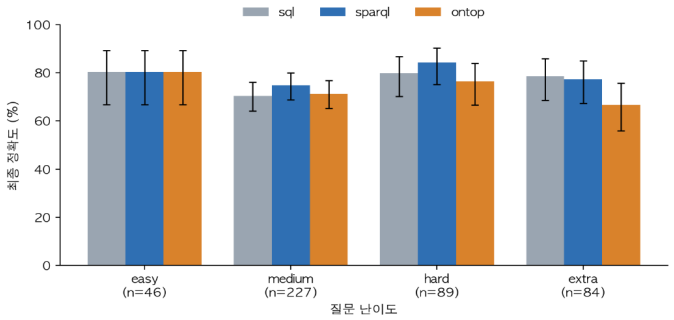
같은 질문에 대해 데이터베이스를 접근하는 방식만 달리한 세 가지 조건을 비교했다. 세 조건은 다음 환경을 공통으로 한다. 에이전트는 모두 동일한 LLM(claude-haiku-5-5)을 사용하며 ReAct[10] 방식(LangChain, LangGraph)으로 구현하였다. 질문에는 BIRD의 evidence를 힌트로 덧붙였고, 질문당 최대 50단계, 반환 결과 최대 50행으로 제한하였으며, 모든 조건과 질문은 한 번씩 실행하였다. 조건 간 차이는 에이전트가 DB에 접근하는 방식뿐이다. sql 조건은 스키마 설명 없이 SQL만으로 PostgreSQL에 질의한다. sparql 조건은 RIGOR가 생성한 OWL 온톨로지를 SPARQL로 먼저 검색하여 관련 클래스, 속성, 원본 테이블·컬럼을 파악한 뒤 SQL로 질의하며, 온톨로지를 검색하기 전의 SQL 호출은 코드로 거절하였다. ontop 조건은 SQL 없이 SPARQL만으로 질의하고 Ontop이 R2RML 매핑으로 이를 SQL로 번역하여 PostgreSQL에서 실행하며, 매핑에 존재하는 클래스와 속성의 목록(도메인과 범위 포함)을 시스템 프롬프트로 제공하였다.
채점은 에이전트가 마지막으로 실행한 SQL의 결과가 정답 SQL의 결과와 행과 컬럼까지 같으면 정답으로 보고, 그렇지 않더라도 에이전트의 자연어 답변에 정답 결과의 모든 값이 포함되어 있으면 정답으로 인정하였다. 이때 숫자의 반올림 차이와 문자열의 대소문자·공백 차이는 허용하였다. 정답 SQL의 결과가 비어 있는 질문은 채점에서 제외하였으며, movie_3의 33개가 제외되어 채점 대상은 movie_3 287개와 synthea 159개를 합한 446개이다. 정확도의 95% 신뢰구간은 Wilson[11] 구간으로 계산하였다.

2.3.2 실험 결과 및 분석

전체 446개 질문에서 최종 정확도는 sparql이 77.8%, sql이 74.9%, ontop이 72.4%였다. sparql이 가장 높았으나 세 조건의 신뢰구간이 서로 겹쳐 차이가 뚜렷하다고 보기는 어렵다. 데이터베이스별로는 movie_3에서 sparql 78.4%, sql 77.4%, ontop 73.5%였고, synthea에서는 sparql 76.7%, sql과 ontop은 각각 70.4%였으며 두 경우 모두 신뢰구간이 겹쳤다. 난이도별 결과는 그림 1에 나타내었다. easy(46개)에서는 세 조건이 모두 80.4%였고, medium(227개)에서는 sparql 74.9%, ontop 71.4%, sql 70.5%였으며, hard(89개)에서는 sparql 84.3%, sql 79.8%, ontop 76.4%였다. extra(84개)에서는 sql 78.6%, sparql 77.4%, ontop 66.7%로 ontop이 가장 낮았으나 신뢰구간은 겹쳤다. easy는 질문이 46개뿐이어서 신뢰구간이 넓다.
데이터베이스별 실행 시간은 표 3과 같다. ontop 조건은 두 데이터베이스 모두에서 가장 오래 걸려, sql 조건 대비 movie_3에서 약 1.7배(2370.4초 대 1415.7초), synthea에서 약 1.6배(1882.1초 대 1194.3초)였다. sparql 조건은 movie_3에서 sql보다 다소 길었고(1561.0초) synthea에서는 다소 짧았다(1069.2초). 질문당 평균으로는 ontop이 movie_3에서 약 7.3초, synthea에서 약 10.2초로 sql(각각 약 4.4초, 6.5초)보다 길었다. 정리하면 온톨로지를 스키마 탐색에 활용한 조건이 가장 높은 정확도를 보였으나 모든 비교에서 신뢰구간이 겹쳤고, 실행 시간은 ontop 조건이 가장 길었다.

<표 3> 데이터베이스별 실행 시간(단위: 초)

방식	movie_3	synthea
sql	1415.7	1194.3
sparql	1561.0	1069.2
ontop	2370.4	1882.1



<그림 1> 난이도별 최종 정확도(오차 막대는 Wilson 95% 신뢰구간)

3. 결 론

본 연구는 DB로부터 자동 생성한 온톨로지를 LLM 에이전트의 질의에 활용하였을 때의 정확도를 DB만 사용한 경우와 비교하고, 온톨로지의 두 연결 방식을 비교하였다. BIRD train의 movie_3와 synthea에서 세 조건(sql, sparql, ontop)으로 질문 446개를 난이도별로 평가한 결과, easy에서는 세 조건이 같았고, medium과 hard에서는 sparql이 가장 높았으며, 질의가 복잡한 extra에서는 ontop이 가장 낮았으나 이 경우에도 신뢰구간은 겹쳤다. 다만 온톨로지를 스키마 탐색에 활용한 조건은 DB만 사용한 조건보다 미세하게 높았고, SPARQL을 SQL로 변환하는 ontop 조건은 DB만 사용한 조건보다 다소 낮았다. 실행 시간은 sparql 조건이 sql 조건과 유사한 수준이었고, ontop 조건은 두 데이터베이스 모두에서 약 1.6~1.7배로 가장 길었다. 이는 온톨로지를 스키마 탐색에 활용하는 방식이 질의 언어를 바꾸는 방식보다 안정적일 가능성을 시사한다. 다만 데이터베이스가 두 개뿐이고 조건마다 한 번씩만 실행하였으며 에이전트 모델도 하나이고 evidence를 준 조건만 측정하였으므로, 더 다양한 구조의 데이터베이스와 여러 모델, 반복 실행, evidence를 주지 않은 조건으로 결과를 확인하는 연구가 필요하다. 현재 RIGOR의 스키마 형식은 컬럼 하나로 이루어진 외래 키만 표현하여 복합 외래 키가 있는 데이터베이스를 다룰 수 없으므로, 다양한 데이터베이스에 적용하려면 복합 외래 키를 처리하도록 확장할 필요가 있다. 아울러 본 연구의 채점은 정답 SQL의 결과와 일치하는지를 기준으로 하였으므로, 온톨로지가 연결해 주는 관련 정보로 답변이 풍부해질 수 있는 효과는 반영하지 못하였다. 이를 확인하기 위해서는 답변 내용의 의미를 분석하는 평가가 필요하다.

[참 고 문 헌]

[1] J. Li et al., “Can LLM already serve as a database interface? A BIg bench for large-scale database grounded text-to-SQLs”, Advances in Neural Information Processing Systems (NeurIPS), vol. 36, 2023.
[2] J. Sequeda, D. Allemang, and B. Jacob, “A benchmark to understand the role of knowledge graphs on large language model’s accuracy for question answering on enterprise SQL databases”, Proc. GRADES-NDA, pp. 1-12, 2024.
[3] C. Pinkel et al., “RODI: Benchmarking relational-to-ontology mapping generation quality”, Semantic Web, vol. 9, no. 1, pp. 25-52, 2018.
[4] L. Laskowski, M. Hladik, J. Portisch, F. Panse, and F. Naumann, “Burr: A benchmark for ontology learning from relational databases”, Proc. ACM Manag. Data, vol. 3, no. 6, 2025.
[5] N. Fathallah et al., “Retrieval-augmented generation of ontologies from relational databases”, Proc. Int. Semantic Web Conf. (ISWC), 2026.
[6] G. Xiao et al., “The virtual knowledge graph system Ontop”, Proc. Int. Semantic Web Conf. (ISWC), LNCS vol. 12507, pp. 259-277, 2020.
[7] R. Diestel, Graph Theory, 5th ed., Springer, 2017.
[8] M. Bianchi, A. Cornaro, J. L. Palacios, and A. Torriero, “New bounds of degree-based topological indices for some classes of c-cyclic graphs”, Discrete Appl. Math., vol. 184, pp. 62-75, 2015.
[9] T. Yu et al., “Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task”, Proc. Conf. Empirical Methods Natural Lang. Process. (EMNLP), pp. 3911-3921, 2018.
[10] S. Yao et al., “ReAct: Synergizing reasoning and acting in language models”, Proc. Int. Conf. Learn. Represent. (ICLR), 2023.
[11] E. B. Wilson, “Probable inference, the law of succession, and statistical inference”, J. Am. Stat. Assoc., vol. 22, no. 158, pp. 209-212, 1927.